

Final Assignment Kapita Selekt SC: Analisis Saturasi & Halusinasi pada RAG

A. Metode

a. Dataset

Penelitian ini menggunakan dataset IDK-MRC (Indonesian Knowledge - Machine Reading Comprehension) yang diakses melalui library datasets HuggingFace (rifkiaputri/idk-mrc). Dataset ini berisi pasangan konteks, pertanyaan, dan jawaban dalam Bahasa Indonesia.

Dari split *train*, diperoleh:

- 3.659 dokumen konteks unik yang digunakan sebagai *corpus* untuk vector store
- 5.042 pasangan tanya-jawab (*is_impossible = False*) yang valid untuk dievaluasi

Untuk eksperimen, dilakukan *sampling* sebanyak 100 pasangan QA.

b. Embedding Model

Representasi vektor untuk setiap dokumen dan query dihasilkan menggunakan model paraphrase-multilingual-MiniLM-L12-v2 dari library sentence-transformers. Model ini dipilih karena:

1. Bersifat *lightweight*
2. Mendukung Bahasa Indonesia (multilingual)
3. Menghasilkan embedding berdimensi 384, cukup untuk *semantic similarity search*

c. Vector Store

Sistem retrieval menggunakan FAISS (Facebook AI Similarity Search) dengan tipe index IndexFlatL2, yaitu pencarian *exact nearest neighbor* berbasis jarak Euclidean (L2 distance). Seluruh 3.659 dokumen di-encode menjadi matrix embedding berukuran (3659, 384) dan disimpan ke dalam index FAISS untuk pencarian similarity secara *in-memory*.

d. Mekanisme Top-K Retrieval

Fungsi retrieve(query, k) mengambil K dokumen dengan jarak L2 terkecil terhadap embedding query. Sistem diuji dengan empat variasi nilai K = 1, 3, 5,

dan 10 untuk menganalisis pengaruh jumlah konteks terhadap kualitas jawaban dan akurasi sitasi.

Setiap hasil retrieval mengembalikan:

- doc_id: identitas unik dokumen dalam corpus
- text: isi dokumen
- score: jarak L2 terhadap query (semakin kecil = semakin relevan)
- rank: peringkat relevansi (1 = paling relevan)

Output retrieval ini diteruskan ke modul *generation* melalui fungsi `get_context_for_generation(query, k)` yang mengembalikan struktur data berisi query dan daftar dokumen siap dimasukkan ke dalam prompt LLM.

e. Large Language Model (LLM)

Tahap generasi jawaban pada sistem RAG menggunakan model Qwen2.5-1.5B-Instruct dari Hugging Face. Model ini dipilih karena memiliki kemampuan instruction-following yang baik, ukuran model yang relatif ringan dibanding model LLM lainnya, serta dapat dijalankan secara efisien menggunakan teknik quantization 4-bit.

Untuk mengurangi kebutuhan memori GPU, model dimuat menggunakan BitsAndBytes dengan konfigurasi 4-bit quantization (NF4). Pendekatan ini memungkinkan proses inferensi dilakukan dengan konsumsi memori yang lebih rendah tanpa penurunan performa yang signifikan.

Model digunakan untuk menghasilkan jawaban berdasarkan dokumen hasil retrieval yang diperoleh dari FAISS.

f. Desain Prompt

Prompt dirancang untuk membatasi model agar hanya menggunakan informasi yang tersedia pada dokumen hasil retrieval.

Setiap prompt berisi:

- Dokumen hasil retrieval
- Pertanyaan pengguna
- Instruksi penggunaan konteks
- Format jawaban dan sitasi dokumen

Instruksi yang diberikan kepada model meliputi:

1. Menggunakan hanya informasi dari dokumen yang diberikan.
2. Menyatakan bahwa informasi tidak ditemukan apabila jawaban tidak tersedia dalam dokumen.
3. Menyertakan nomor dokumen sebagai sumber jawaban.

Pendekatan ini digunakan untuk mengurangi kemungkinan halusinasi dan meningkatkan akurasi sitasi pada sistem RAG.

g. Pipeline RAG End-to-End

Pipeline RAG terdiri dari tiga tahap utama:

1. Query Encoding
2. Retrieval menggunakan FAISS dengan nilai K tertentu
3. Generation menggunakan model Qwen2.5-1.5B-Instruct

Untuk setiap pertanyaan, sistem melakukan retrieval sebanyak K dokumen paling relevan ($K = 1, 3, 5$, dan 10). Dokumen hasil retrieval kemudian dimasukkan ke dalam prompt dan digunakan oleh LLM untuk menghasilkan jawaban akhir beserta sitasinya.

B. Hasil Eksperimen


a. Metrik ROUGE/BLEU/BERTScore

Hasil pengujian sistem RAG terhadap variasi nilai K (1, 3, 5, dan 10) menggunakan 100 sampel data dari IDK-MRC ditunjukkan pada Tabel 1 berikut.

Tabel 1. Hasil Agregasi Metrik Kualitas Jawaban dan Akurasi Sitasi


K	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	BERTScore F1	Citation Acc.
1	0.3126	0.1977	0.3113	0.2085	0.7278	0.4300
3	0.4301	0.2820	0.4295	0.3038	0.7624	0.6000
5	0.4388	0.2947	0.4365	0.3386	0.7778	0.5300
10	0.1918	0.1149	0.1902	0.1404	0.6587	0.2200

C. Analisis dan Diskusi



Gambar 1. Grafik Performa Metrik vs K

Berdasarkan hasil eksperimen menggunakan 100 dataset IDK-MRC, dapat dilihat pada **Gambar 1**, semua metrik (ROUGE-1, ROUGE-2, ROUGE-L BLEU, dan BERTScore) kualitas jawaban terhadap variasi nilai K, berawal dari nilai K=1 hingga K=5 mengalami peningkatan, tetapi ketika menuju K=10 mengalami penurunan. Hal ini terjadi saturasi performa karena LLM berukuran kecil (Qwen2.5-1.5B) yang memiliki keterbatasan dalam memproses konteks yg panjang, sehingga LLM yang digunakan mengalami kesulitan mengidentifikasi bagian mana yang benar-benar relevan. Pada akhirnya bisa saja jawabannya menjadi kurang tepat.



Gambar 2. Grafik Citation Accuracy vs K

Selain itu, dilihat dari akurasi sitasi pada **Gambar 2**, dari $K=1$ hingga $K=3$ mengalami peningkatan, tetapi setelah itu mengalami penurunan dari $K=5$ hingga anjlok drastis pada $K=10$. Hal ini terjadi karena banyaknya dokumen konteks yang diberikan sehingga LLM yang digunakan mengalami kesulitan dalam melacak sumber informasi yang tepat dan pada akhirnya muncul halusinasi sitasi.

Pembagian Kerja

Nama	Bagian
Andi Fayza Maharani	Code
	Load dataset IDK-MRC dari HuggingFace
	Setup embedding model (sentence-transformers)
	Build vector store (FAISS)
	Implementasi Top-K retrieval ($K = 1, 3, 5, 10$)
	Laporan
	Bagian Metode: arsitektur RAG, embedding, retriever
	Tabel hasil metrik ROUGE/BLEU/BERTScore
Rocky Arthama Putra	Code
	Load LLM (Qwen/Gemma dengan 4-bit quantization)
	Rancang prompt template (termasuk instruksi sitasi dokumen)
	Jalankan pipeline RAG end-to-end untuk semua nilai K
	Laporan
	Bagian Metode: LLM yang dipilih, desain prompt
	Grafik performa metrik vs K
Salwaa Mumtaazah Darmanastri	Code
	Implementasi metrik ROUGE, BLEU, BERTScore
	Hitung citation accuracy (persentase sitasi benar per K)
	Agregasi semua hasil eksperimen ke tabel/dataframe
	Laporan
	Bagian Analisis & Diskusi: saturasi performa, perilaku halusinasi sitasi
	Grafik citation accuracy vs K